분류 모델의 한계

Towards open set deep networks(CVPR 2016)

분류 심층 신경망의 구조

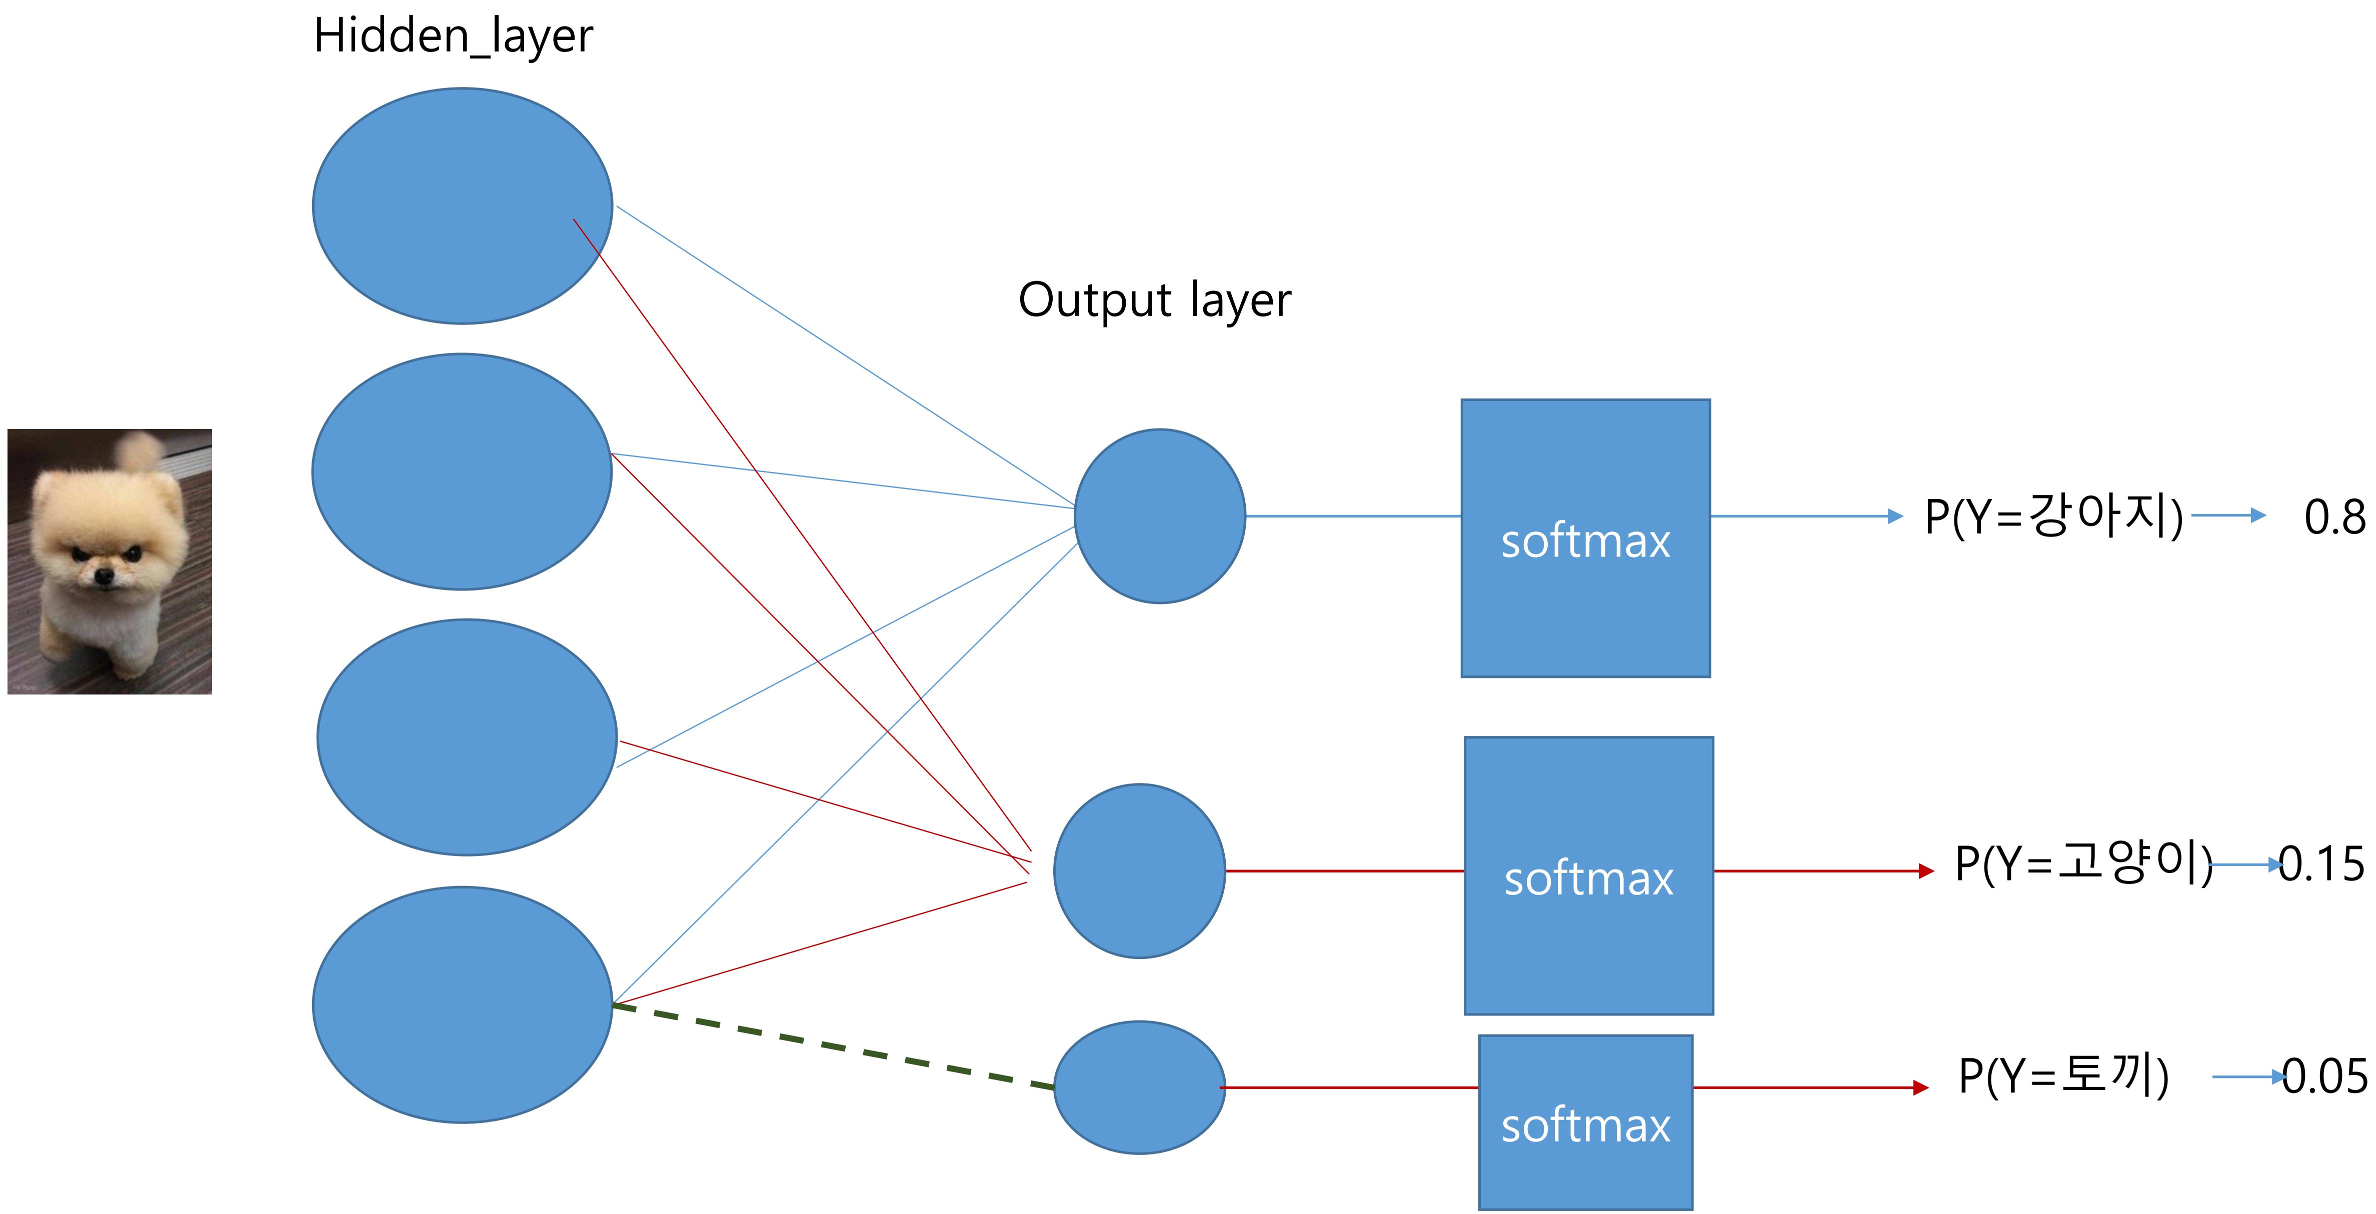
Hidden_layer
Output layer
softmax
softmax
softmax
P(Y=강아지)
0.8
P(Y=고양이)
0.15
P(Y=토끼)
0.05

Softmax,Logit vector

softmax

$$y_k = \frac{\exp(a_k)}{\sum_{i=1}^{n} \exp(a_i)}$$

```
>>> a = np.array([0.3, 2.9, 4.0])
>>> y = softmax(a)
>>> print(y)
[ 0.01821127  0.24519181  0.73659691]
>>> np.sum(y)
1.0
```

①: y[0]일 확률, ②: y[1]일 확률 ...

각 클래스일 확률을 반환해줌

Logit vector

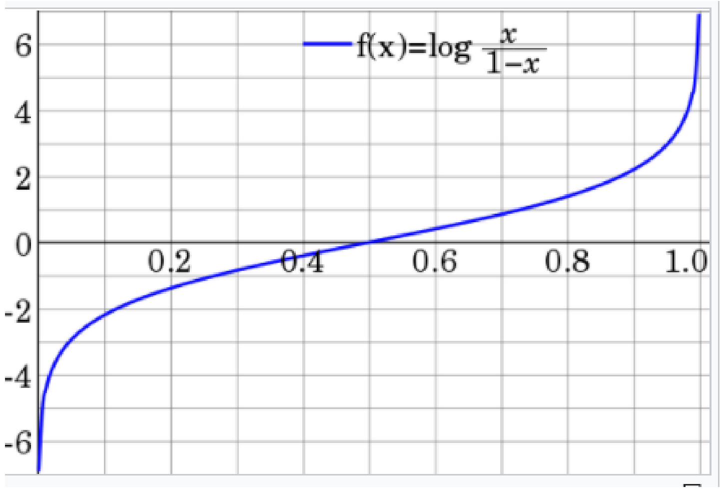

Sigmoid 함수의 역함수
신경망의 마지막 계층은 로짓 계층으로 예측에 대한 원시 값을 반환

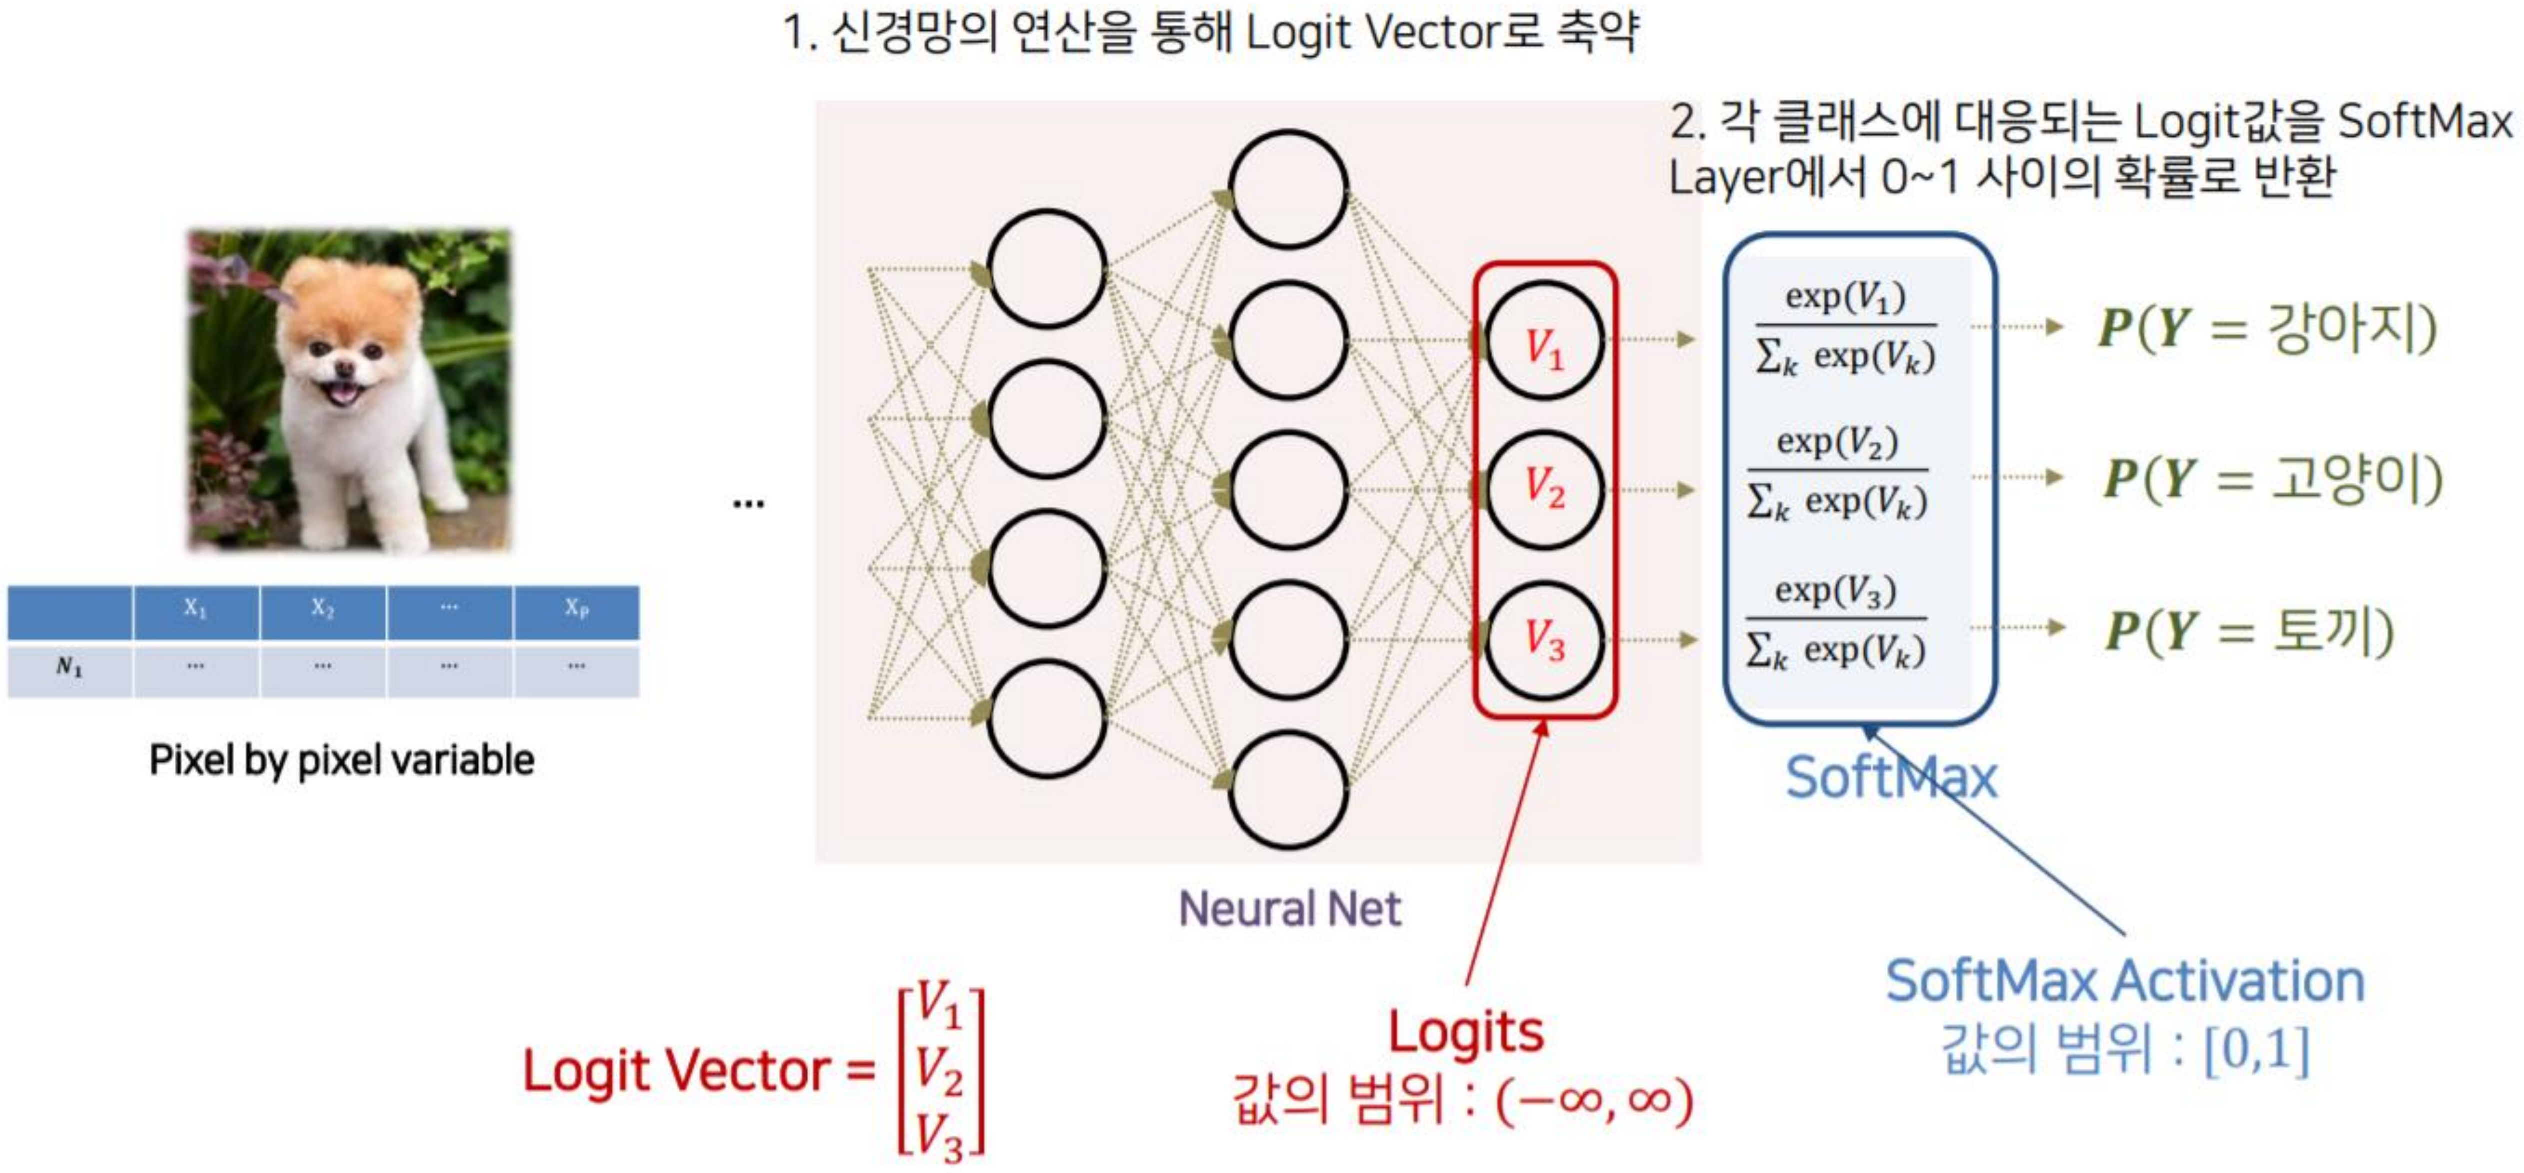

출처 : 고대 김상훈씨 세미나 자료

분류 모델의 한계점

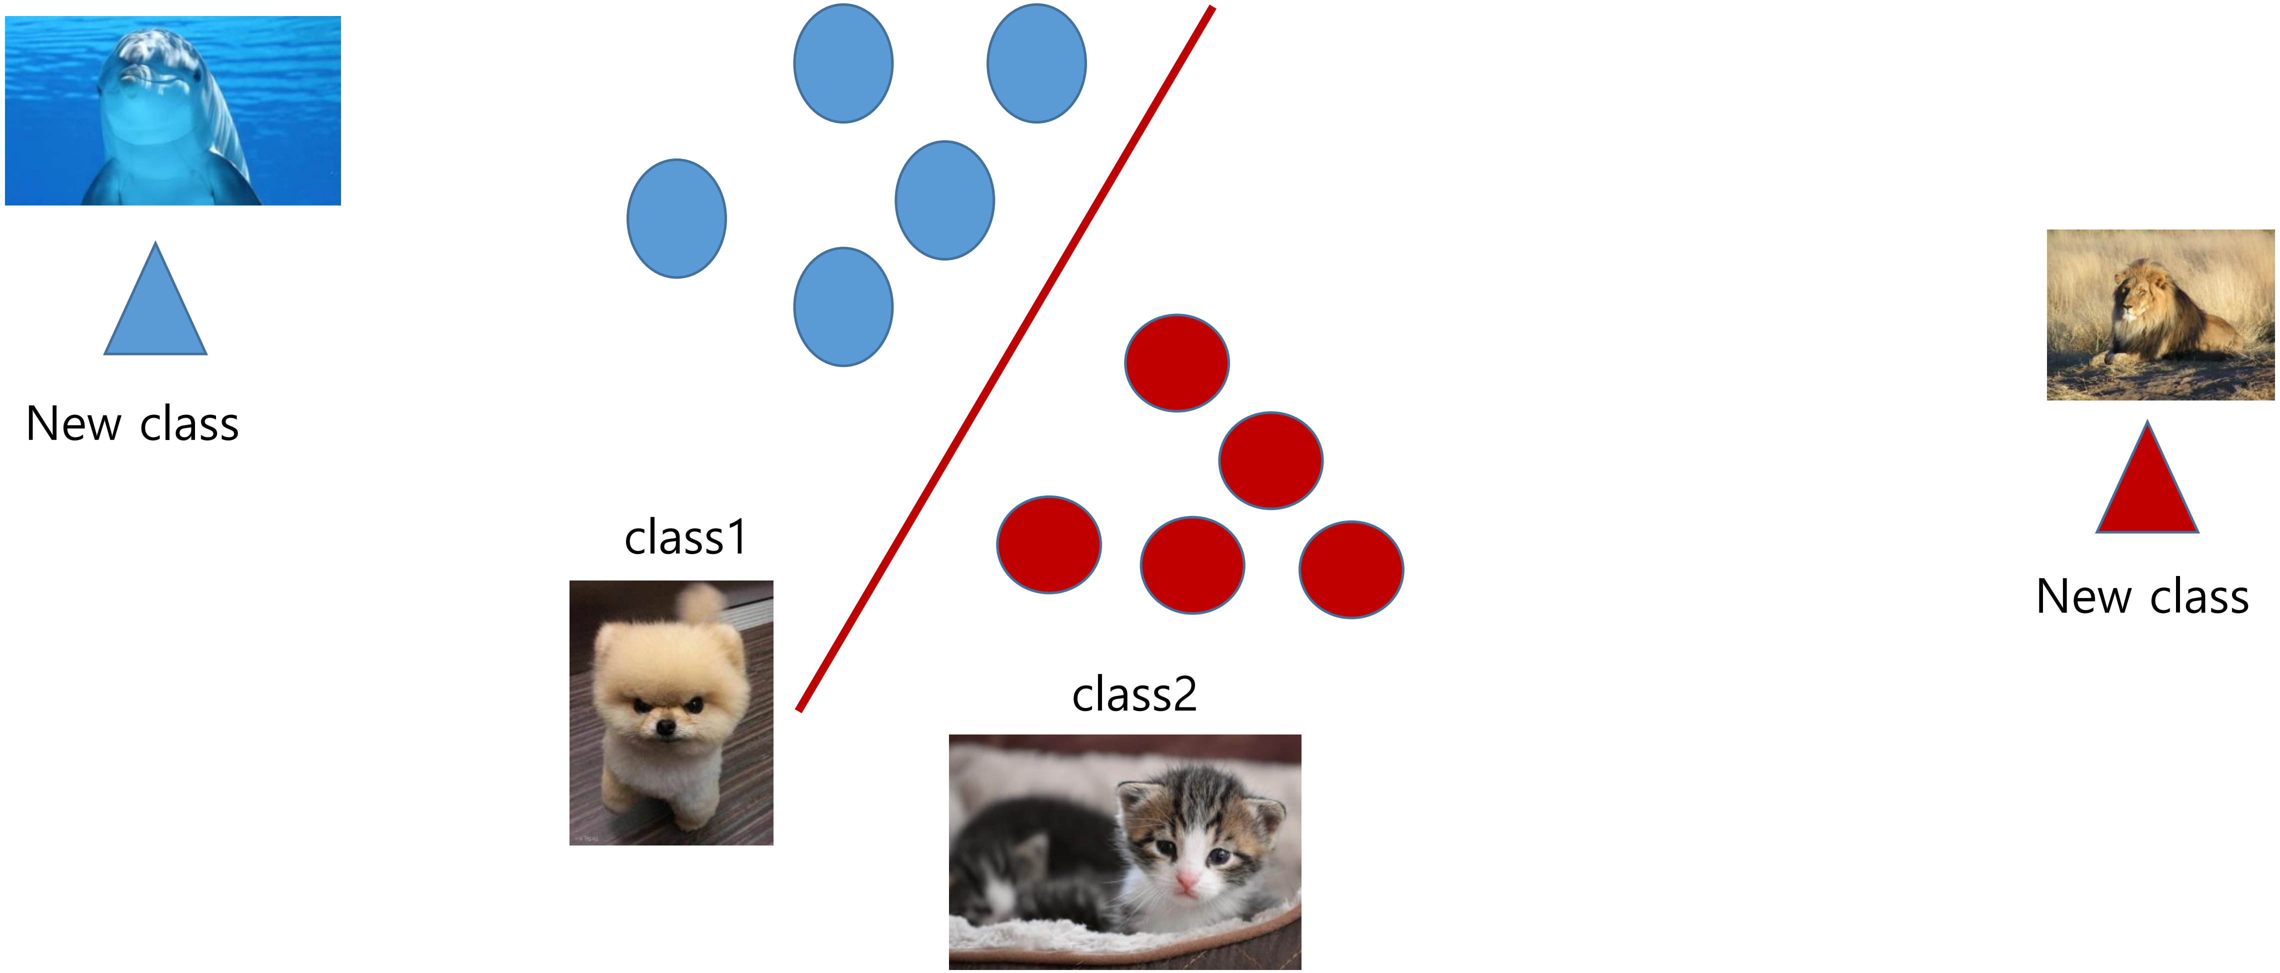

만약 전혀 다른 동물이 들어간다면?

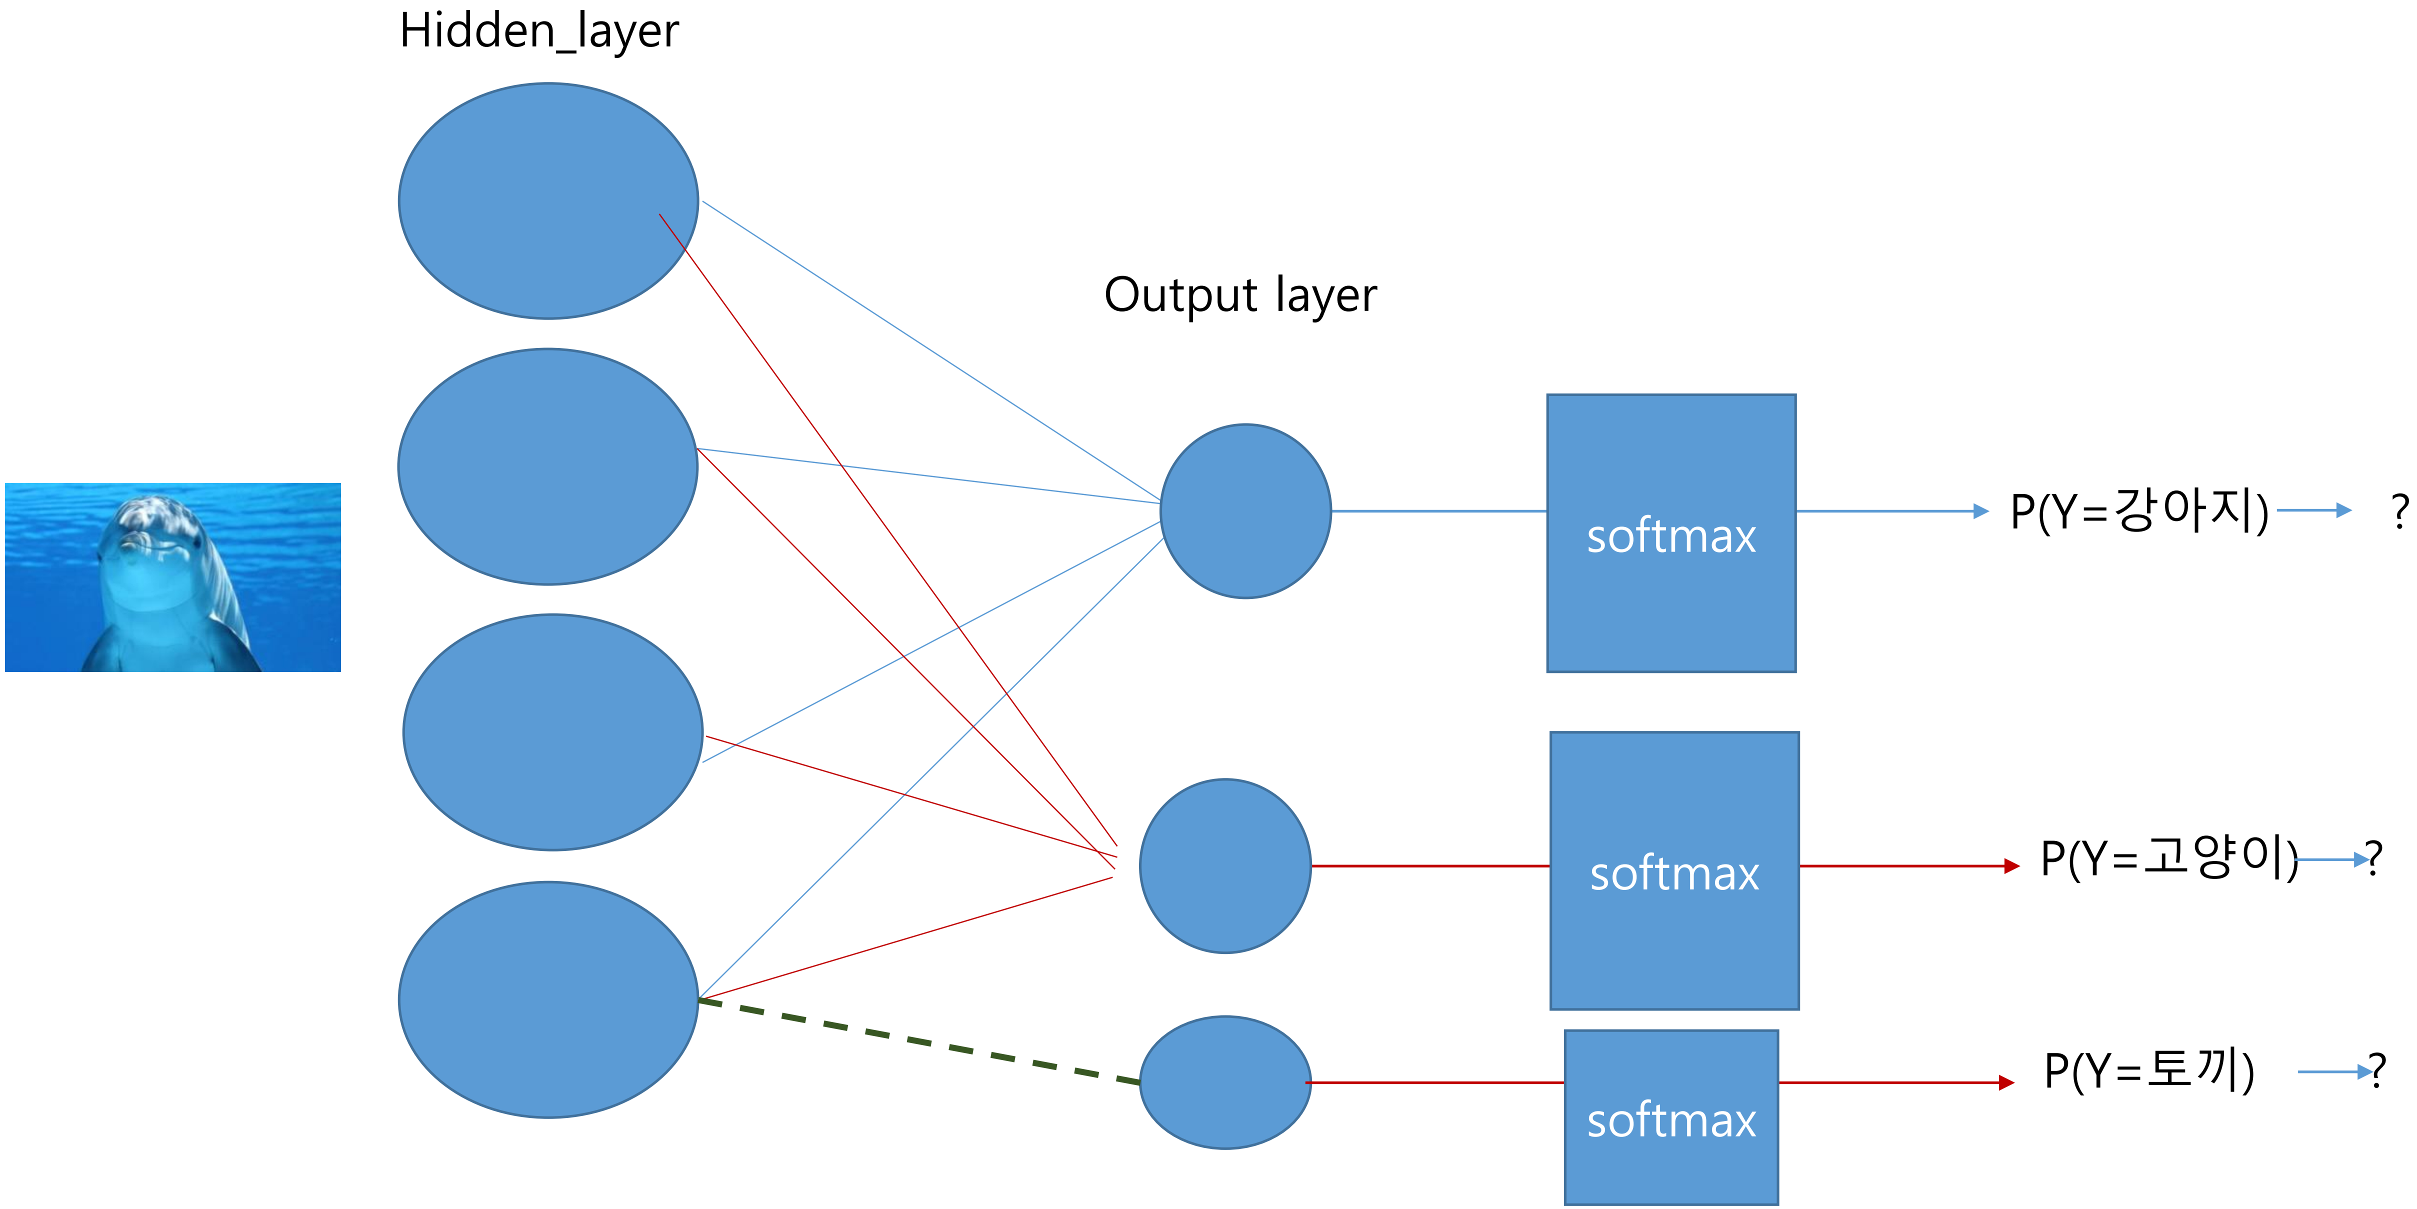

이를 극복하기 위해선..?

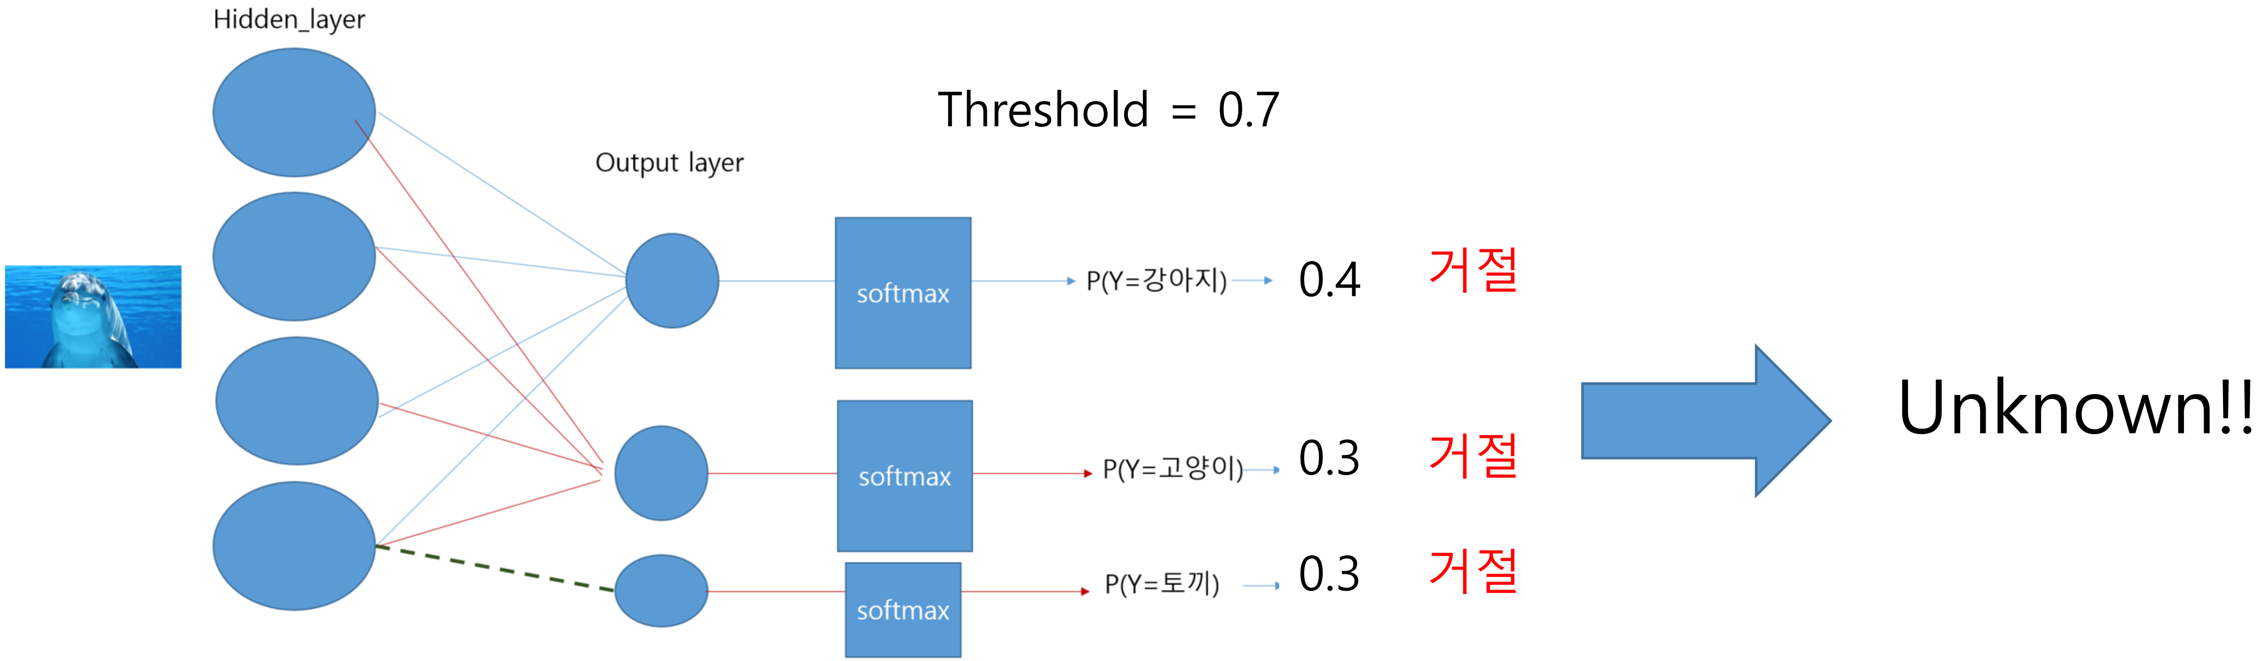
Hidden_layer
Threshold = 0.7
Output layer
softmax
P(Y=강아지)
0.4
거절
softmax
P(Y=고양이)
0.3
거절
softmax
P(Y=토끼)
0.3
거절
Unknown!!

Closed Set vs OpenSet Recognition

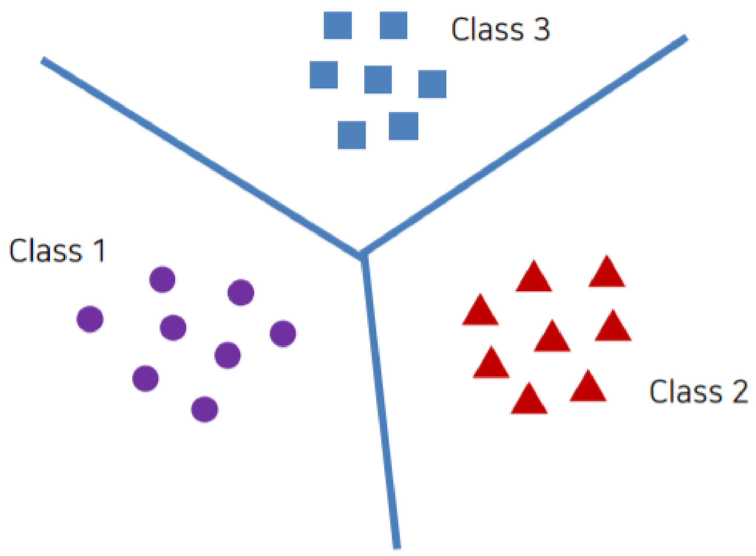

Closed Set Classification

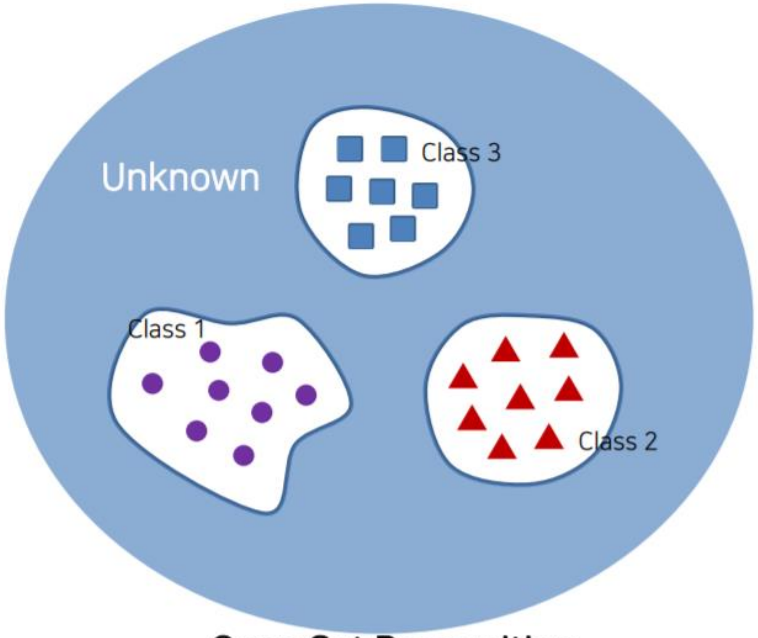

Open Set Recognition

Open Set Recognition 종류

Adversarial Learning-based

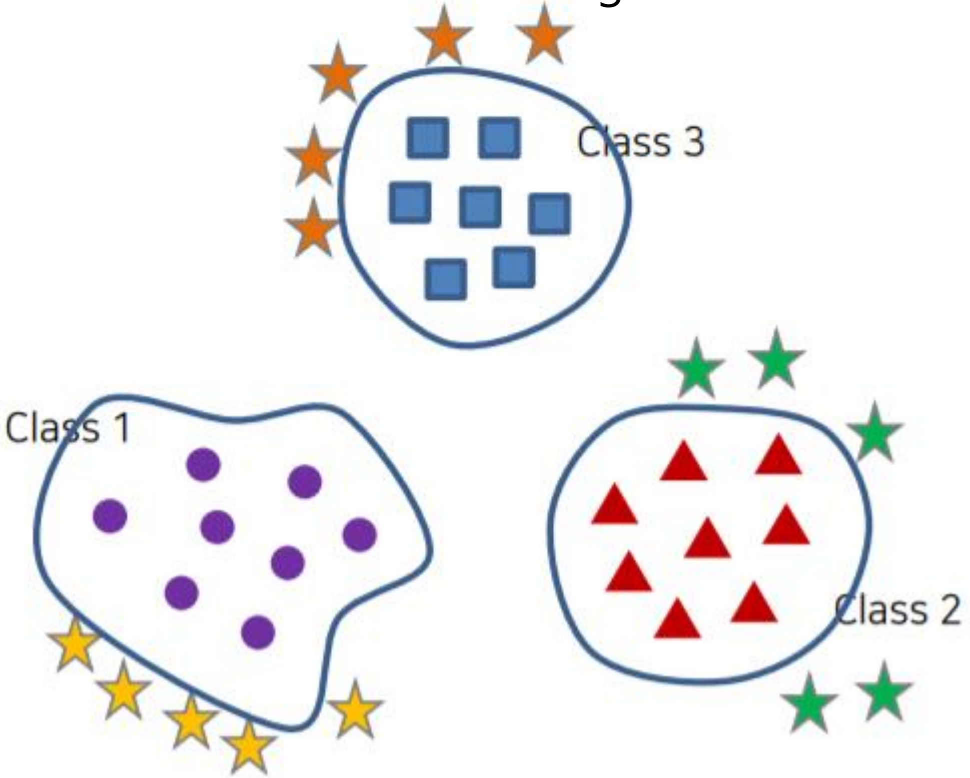

GAN 등의 생성모델을 통해 각 클래스와 비슷한
다른 이미지들을 생성하여 새로운 클래스로 추가 학습

Distance-Based

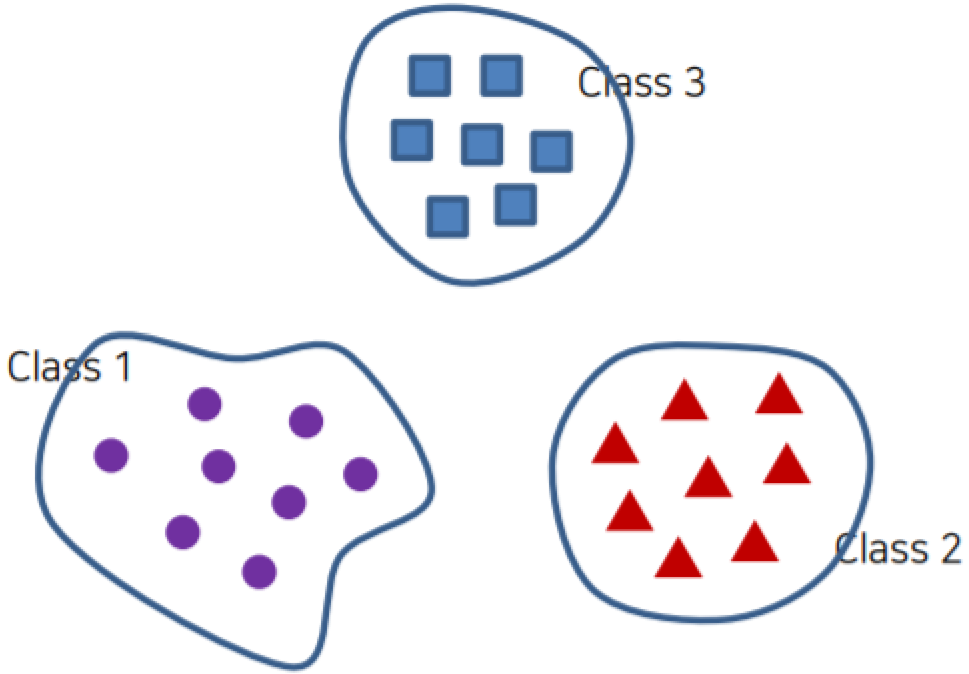

평균부터 떨어진 거리, 마진 등을
통하여 결정 경계 생성

논문에선 EuCos 거리 사용

OpenMAX

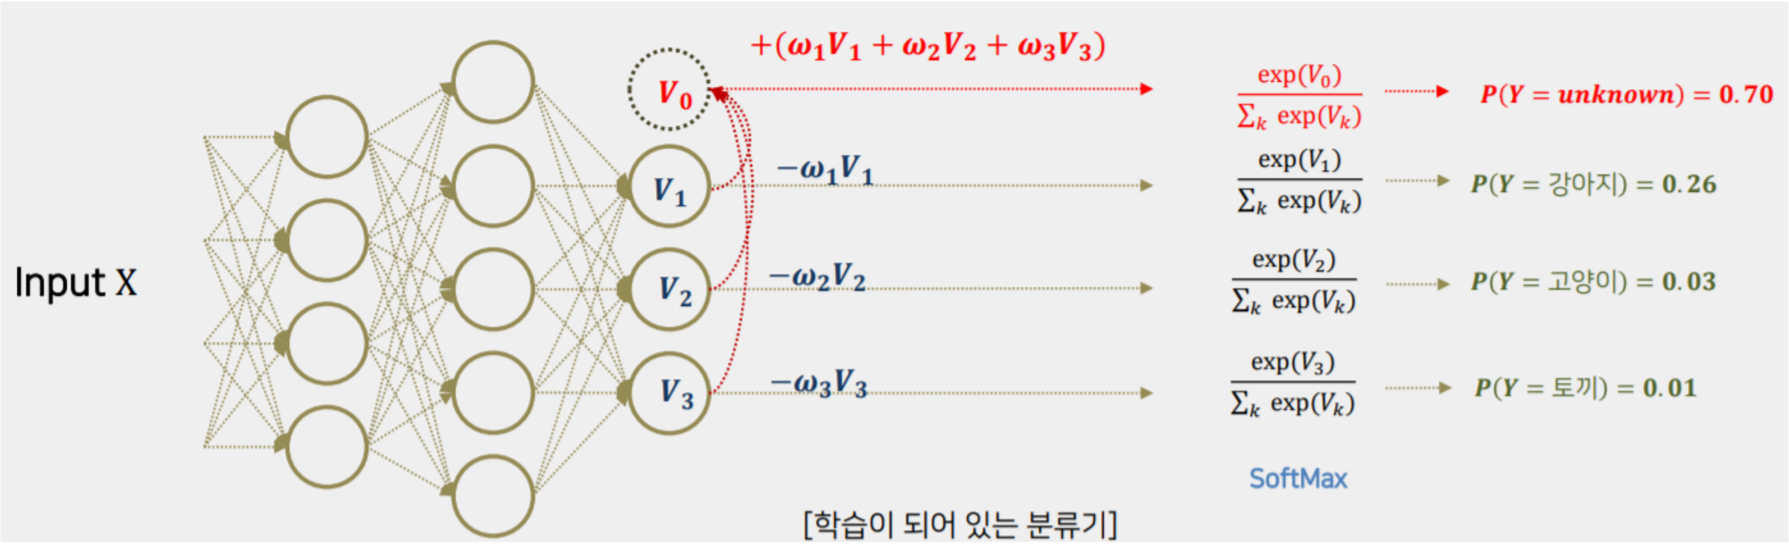

V_k = logit 값

W_k = 분류기가 k class로 잘못 분류했을 때 대응하는 가중치

W_k를 어떻게 정의하냐?

Extreme value theorem(최대최소정리)에 기반하여 평균 Logit Vector로부터의 거리에 대한 극단값(이상치)의 분포를 통해 w_k를 정의한다

Extreme value theorem(1)

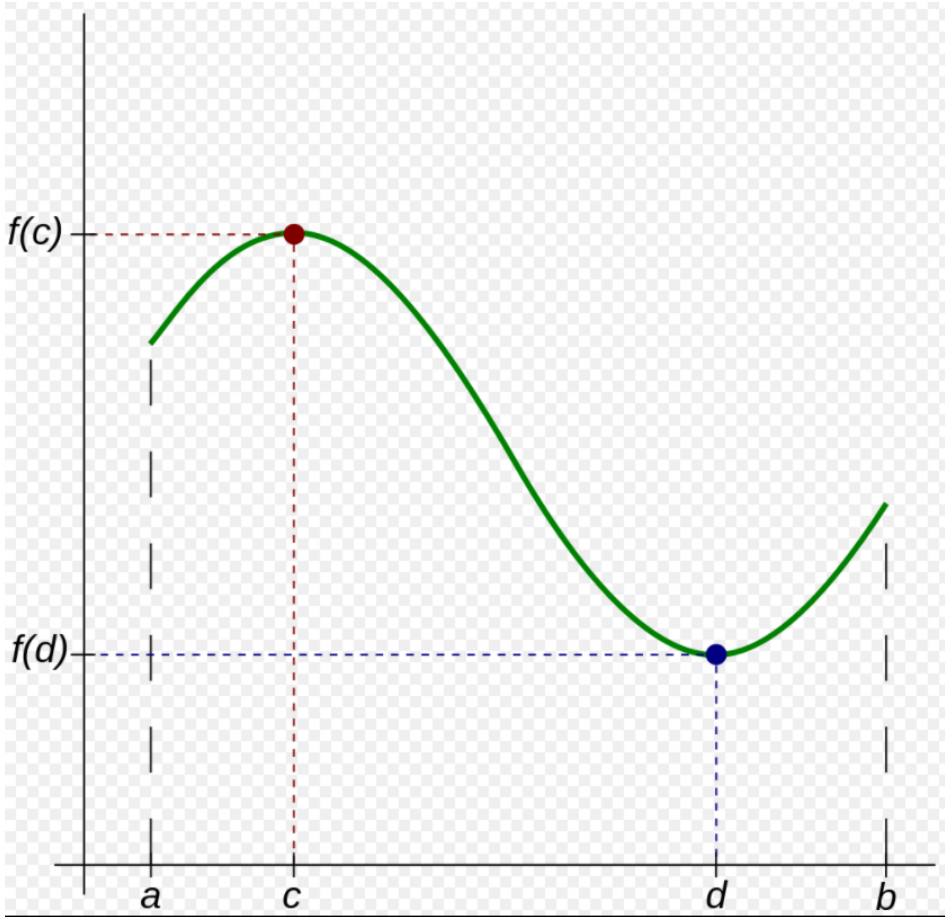

닫힌구간 [a, b]에서 연속인 함수 f는 최댓값 f(c)와 최솟값 f(d)를 반드시 갖는다

OpenMAX Flow

1. 학습 데이터 중 분류기가 정확하게 선별한 데이터 선별
2. 선별된 데이터의 X(input)데이터를 클래스별로 분리
3. 각 클래스 별로 선별된 데이터를 이용하여 Logit Vector 계산
4. 각 클래스 별 평균 Logit Vector의 평균 계산

Obs.	V_1	V_2	V_3
N_{11}	9.87	-2.13	-6.23
N_{12}	18.5	3.18	4.98
…	…	…	…
N_{1a}	4.89	-3.91	1.01

$\overline{V_1} = 5.12$ $\overline{V_2} = -1.12$ $\overline{V_3} = 0.12$

<강아지 클래스 Logit Vector Matrix>

$$\mu_{rabit} = \begin{bmatrix} 1.32 \\ -2.35 \\ 9.32 \end{bmatrix}$$

<토끼 클래스 평균 Logit Vector>

$$\mu_{cat} = \begin{bmatrix} 0.12 \\ 11.27 \\ -3.53 \end{bmatrix}$$

<고양이 클래스 평균 Logit Vector>

$$\mu_{dog} = \begin{bmatrix} 5.12 \\ -1.12 \\ 0.12 \end{bmatrix}$$

<강아지 클래스 평균 Logit Vector>

4번 과정 수행 후 출력값

OpenMAX Flow

5. 각 클래스 별 평균 Logit Vector와의 거리 계산(반복)

Ex.

Obs.	V_1	V_2	V_3
N_{11}	9.87	-2.13	-6.23
N_{12}	18.5	3.18	4.98
…	…	…	…
N_{1a}	4.89	-3.91	1.01

$\overline{V_1} = 5.12$ $\overline{V_2} = -1.12$ $\overline{V_3} = 0.12$

<강아지 클래스 Logit Vector Matrix>

$$\left\| \underset{\text{N11}}{\begin{bmatrix} 9.87 \\ -2.13 \\ -6.23 \end{bmatrix}} - \underset{\text{Logit\_avg}}{\begin{bmatrix} 5.12 \\ -1.12 \\ 0.12 \end{bmatrix}} \right\|$$

간단하게 유클리디안 거리 사용

OpenMAX Flow

6. 각 클래스 별로 계산된 거리 Matrix를 거리 기준 내림차순으로 정렬 후 평균 Logit Vector와 가장 거리가 큰 n개를 각 클래스 별로 추출

왜 굳이 뽑을까???

Extreme value theorem(2) The Fisher-Tippet Theorem

동일분포에서 독립적으로 추출한 변수의 샘플 중 가장 큰 값을 뽑으면, 가장 큰 값보다 클 확률은 Weibull 분포, Frechet 분포, Gumbel 분포의 형태로 만들 수 있다.

극단값, 이상치의 분포를 추정할 수 있다!!!!

$$F(x;\mu,\sigma,0) = e^{-e^{-(x-\mu)/\sigma}} \quad \text{for} \quad x \in \mathbb{R}.$$

Gumbel 분포

$$F(x;\mu,\sigma,\xi) = \begin{cases} e^{-y^{-\alpha}} & y > 0 \\ 0 & y \le 0. \end{cases}$$

Frechet 분포

$$F(x;\mu,\sigma,\xi) = \begin{cases} e^{-(-y)^{\alpha}} & y < 0 \\ 1 & y \ge 0 \end{cases}$$

Weibull 분포

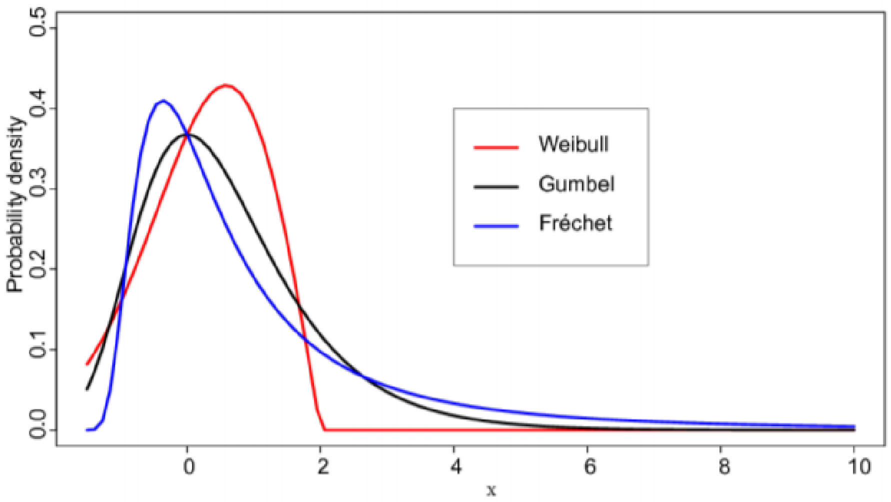

OpenMAX Flow

7. 각 클래스별로 거리가 가장 큰 n개의 샘플로 최대 가능도 추정을 통해 극단치 분포의 파라미터를 추정한다.

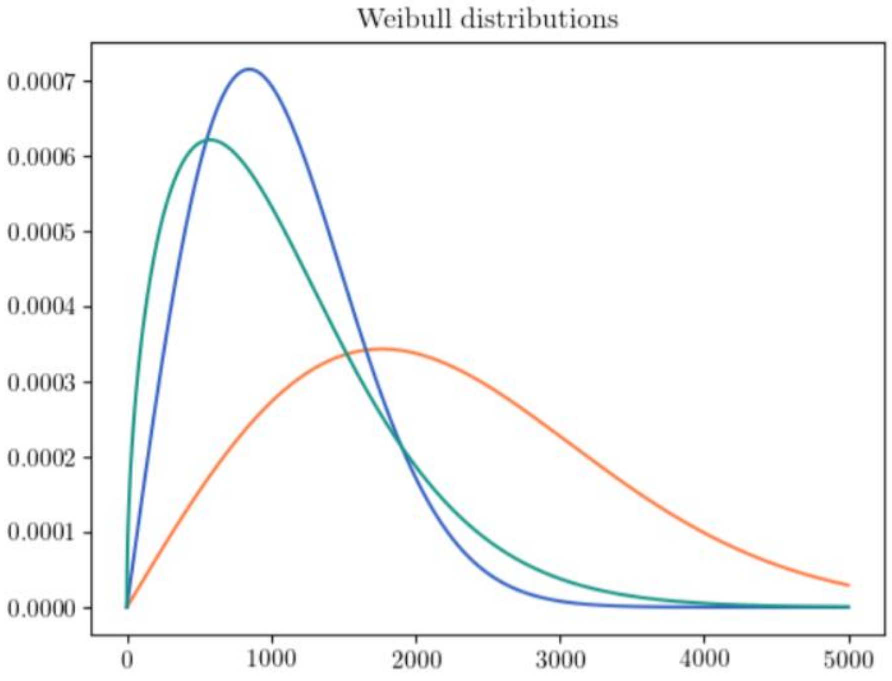

OpenMAX Flow

8. 새로운 데이터를 넣고 Logit Vector를 계산하고 기존 클래스의 평균 logit vector와 거리를 계산한다

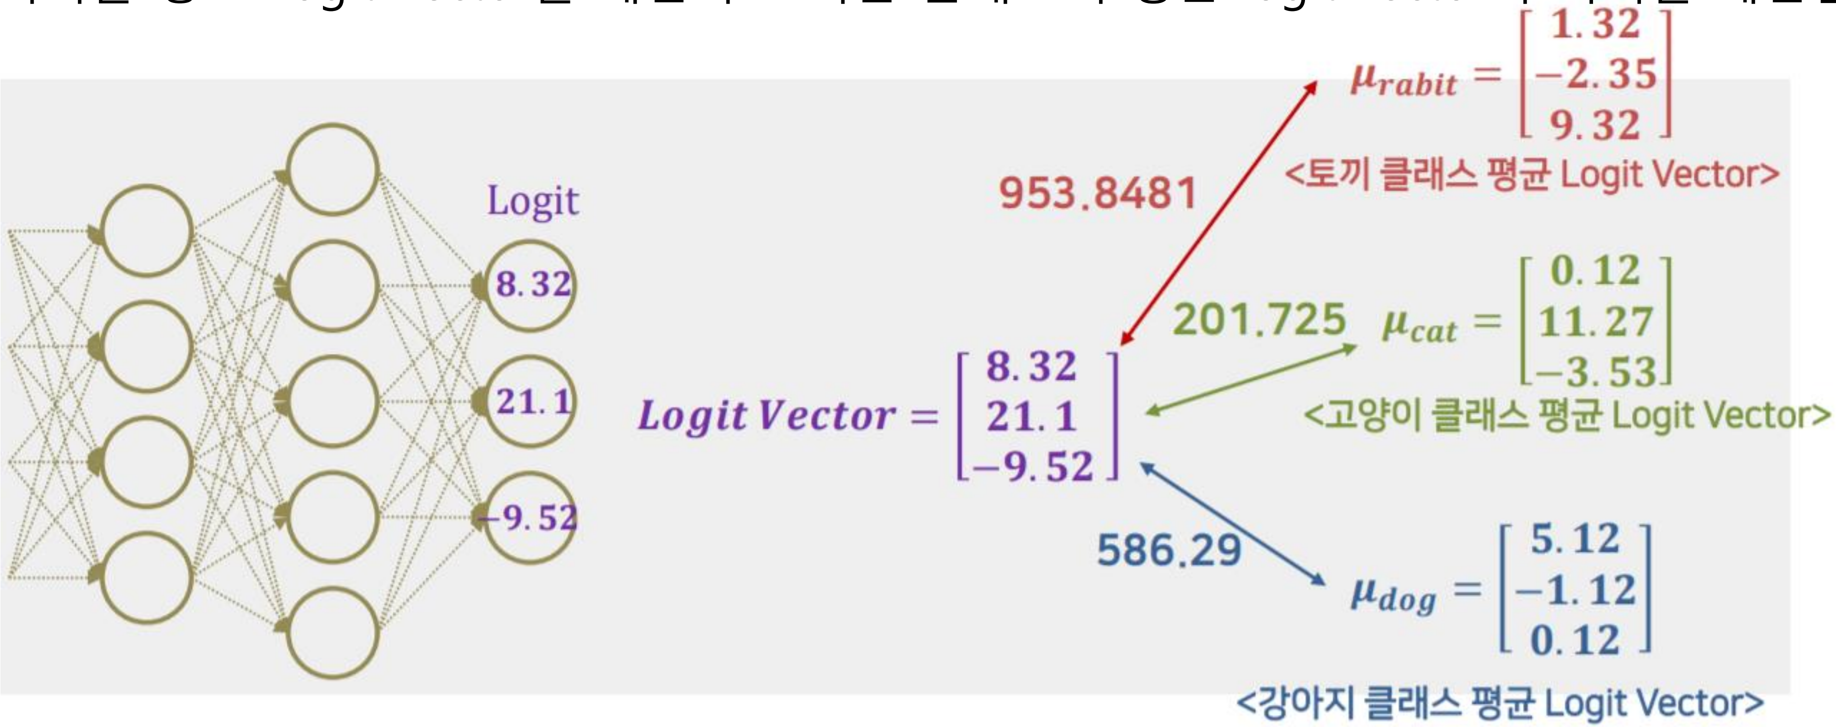

OpenMAX Flow

- 각 클래스 별 생성된 극단분포의 CDF(누적 분포)를 통해 평균 Logit Vector와의 거리 극단 확률 계산

클래스 별 극단값 분포도

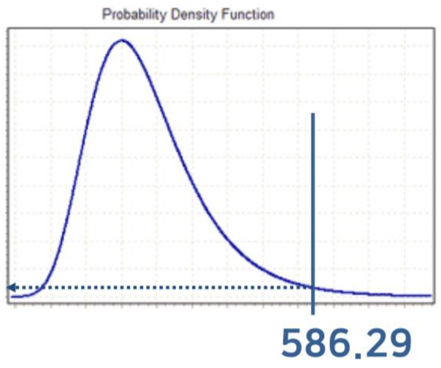

강아지 클래스의 확률 밀도 함수

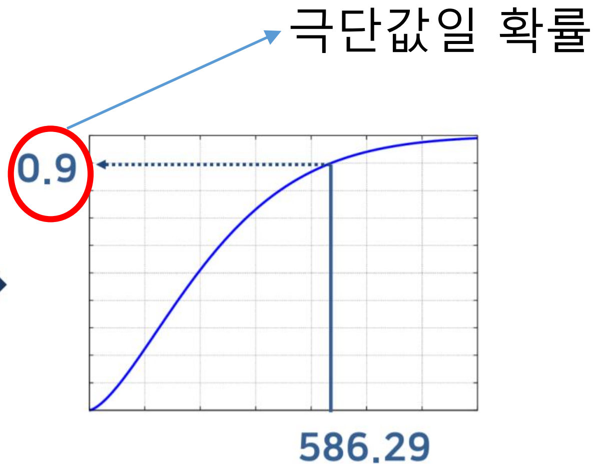

강아지 클래스의 CDF

OpenMAX Flow

8. 극단 분포의 CDF값(극단값일 확률)을 w_k로 두어 Logit Vector 업데이트

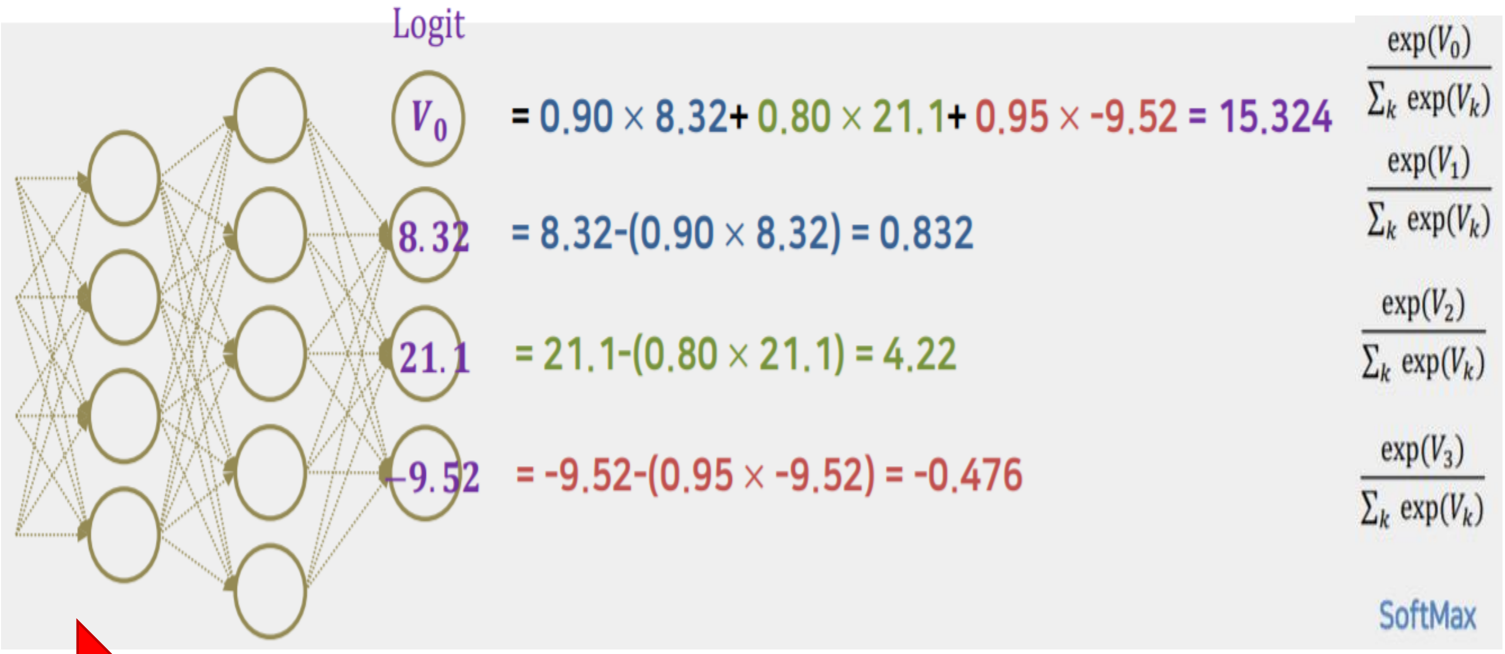

0.7 ?

0.03 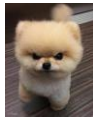

0.26 

0.01 

UnKnown으로 예측!!!