




SVM(Support Vector Machine)

- : Large Margin Classification이라고도 함
- : SVM 분류기는 클래스 사이에 가장 폭이 넓은 마진을 찾는 것
- : 특성의 스케일에 민감



하드 마진 SVM (Hard Margin SVM)

- 오분류를 허용하지 않는 SVM
- 노이즈로 인해 최적의 결정 경계를 잘못 구하거나, 못 찾을 수 있음



소프트 마진 SVM (Soft Margin SVM)

- 오분류를 허용하는 SVM
- 하드 마진 SVM은 적용하기가 어려우므로 어느 정도의 오류를 허용하는 소프트 마진 SVM을 주로 이용


마진오류 결정파라미터 : $C \rightarrow C \uparrow \rightarrow$ 마진오류 ↓ \Rightarrow Hard margin classification
 $C \downarrow \rightarrow$ 마진오류 ↑ \Rightarrow Soft Margin classification

If SVM overfit $\Rightarrow C \downarrow$

비선형 SVM

Kernel Trick을 이용하여 매핑

-> 고차원 공간으로 매핑하는 경우에 증가하는 연산량의 문제를 해결



SVM kernel \Rightarrow Poly로 설정 $\text{coef}_0 \Rightarrow$ 다항식 계열에 있는 상수항 $\text{coef}_0 \uparrow \Rightarrow$ 고차항의 영향 \Downarrow

유사도 특성

: 각 샘플이 특정 랜드마크와 얼마나 닮았는지 측정하는 것

- 가우시안 RBF (유사도 함수)

$$\kappa_r(z, l) = \exp(-\gamma \|z - l\|^2) \Rightarrow \begin{array}{ll} 0 \sim 1 사이 & (0은 랜드마크와 아주 멀리 떨어진 경우) \\ \text{중모양} & (1은 랜드마크와 같은 위치인 경우) \end{array}$$


가우시안 RBF kernel

$\text{kernel} = \text{rbf}$, γ (gamma)

$\gamma \uparrow \rightarrow$ 중모양 (RBF) 좁아짐 \Rightarrow 샘플의 영향 범위 작아짐
 $\gamma \downarrow \rightarrow$ 중모양 (RBF) 넓어짐 \Rightarrow 결정 경계 부드러워짐

규제역할!! \Rightarrow sum Overfit $\Rightarrow \gamma \downarrow$
 \dots under-fit $\Rightarrow \gamma \uparrow$

SVM 수식




\vec{w} 가 경계면을 기준으로 어디 (+, -)에 속하는가?
 $\Rightarrow \vec{w} \cdot \vec{x} \geq C$ (상수) $\Rightarrow +$ else $-$

$\vec{w} \cdot \vec{x}_+ + b \geq 1$
 $\vec{w} \cdot \vec{x}_- + b \leq -1$

$\Rightarrow y_i \begin{cases} 1 & \text{for } + \\ -1 & \text{for } - \end{cases} \Rightarrow y_i (\vec{w} \cdot \vec{x}_i + b) - 1 \geq 0$

S.t (제약식)

\vec{w} : 경계면에 직교하는 벡터
 \vec{x} : 임의의 벡터



목적: Margin 폭을 최대로

$$\begin{aligned} & \downarrow (\vec{x}_+ - \vec{x}_-) \cdot \frac{\vec{w}}{\|\vec{w}\|} \\ &= \underbrace{\begin{cases} \vec{w} \cdot \vec{x}_+ + b \geq 1 \\ \vec{w} \cdot \vec{x}_- + b \leq -1 \end{cases}}_{\vec{w}(\vec{x}_+ - \vec{x}_-) \geq 2} \rightarrow \text{WIDTH} = \frac{2}{\|\vec{w}\|} \end{aligned}$$

라그랑지 승수법 이용

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i |y_i(\vec{w} \cdot \vec{x}_i + b) - 1|$$

w 에 대해 편미분 : $\nabla_w L = \vec{w} - \sum \alpha_i y_i \vec{x}_i = 0$

b 에 대해 편미분 : $\nabla_b L = -\sum \alpha_i y_i = 0 \quad \rightarrow \vec{w} = \sum_i \alpha_i y_i \vec{x}_i$

α 에 대한 maximization 문제로 정리

1. α 를 구하면 w 구할 수 있음
2. $\alpha \neq 0$, \vec{x}_i 가 경계선을 정하는 샘플 즉, Support Vector
3. SVM으로 구한 해는 라그랑지 최적화 이론에 의해 최적의 해 증명 (local Minima에 안빠짐)


SVM 강의

$$\underbrace{w^T x}_{\text{normal vector}} + b = 0$$

hyperplane

Margin: 각 클래스에서 가장 가까운 관측치 사이의 거리
: w 로 표현 가능

SVM에서 좋다는 기준
 \Rightarrow Margin을 최대화 = test 예측 확률화



$$w^T x^+ + b = 1$$

$$w^T (x^+ + \lambda w) + b = 1 \quad (x^+ = x^- + \lambda w)$$

$$w^T x^- + b + \lambda w^T w = 1$$

$$\frac{-1}{\|w\|^2} + \lambda w^T w = 1 \quad \therefore \lambda = \frac{2}{w^T w}$$

x^+ 떨어뜨릴 것

Vector norm = $\|w\|_p = \left(\sum_i |w_i|^p \right)^{\frac{1}{p}}$

ex) L_2 Norm

$$\|w\|_2 = \left(\sum_i |w_i|^2 \right)^{\frac{1}{2}} = \sqrt{w^T w}$$



$$\text{Margin} = \text{distance } (x^+, x^-) = \|x^+ - x^-\|_2 = \|x^- + \lambda w - x^-\|_2 = \|\lambda w\|_2$$

$$= \lambda \sqrt{w^T w} = \frac{2}{w^T w} \cdot \sqrt{w^T w} = \frac{2}{\sqrt{w^T w}} = \frac{2}{\|w\|_2}$$

$$\max \text{ Margin} = \max \frac{2}{\|w\|_2} \Leftrightarrow \min \frac{1}{2} \|w\|_2^2$$

\downarrow 역수

계산 단면의상 제곱 $\Rightarrow \min \frac{1}{2} \|w\|_2^2$

$$\text{minimize } \frac{1}{2} \|w\|_2^2 \leftarrow \text{목적식}$$

$$\text{subject to } y_i(w^T x_i + b) \geq 1 \leftarrow \text{제약식}$$

↳ Margin을 1보단 크게 하자

- 결정 변수 w, b - 목적 함수: margin의 역수 - 제약식: train data를 한 뼈하게 분리하는 조건

- 목적식은 2차식이고 제약식은 선형이다 \Rightarrow 2차 계획법 (QP) \Rightarrow convex optimization (전역최적해 존재)

라고강자 Primal

$$\min L(w, b, a) = \frac{1}{2} \|w\|_2^2 - \sum_{i=1}^n a_i (y_i(w^T x_i + b) - 1)$$

Subject to $a_i \geq 0, i=1, 2, 3, \dots, n$

$$\frac{\partial L(w, b, a)}{\partial w} = 0 \rightarrow w = \sum_{i=1}^n a_i y_i x_i$$

$$\frac{\partial L(w, b, a)}{\partial b} = 0 \rightarrow \sum_{i=1}^n a_i y_i = 0$$

$$\textcircled{1} \quad \frac{1}{2} \|w\|_2^2 = \frac{1}{2} w^T w = \frac{1}{2} \sum_j a_j y_j x_j^T x_j = \frac{1}{2} \sum_j a_j y_j (w^T x_j) = \frac{1}{2} \sum_j a_j y_j (\sum_i a_i y_i x_i^T x_j) = \frac{1}{2} \sum_i \sum_j a_i a_j y_i y_j x_i^T x_j$$

$$\textcircled{2} \quad -\sum_i a_i (y_i(w^T x_i + b) - 1) = -\sum_i a_i y_i (w^T x_i + b) + \sum_i a_i = -\sum_i a_i y_i w^T x_i - b \sum_i a_i y_i + \sum_i a_i = -\sum_i \sum_j a_i a_j y_i y_j x_i^T x_j + \sum_i a_i$$

$$\text{maximize } \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_i a_j y_i y_j x_i^T x_j$$

Subject to $\sum_{i=1}^n x_i y_i = 0, a_i \geq 0, i=1, 2, 3, 4, \dots, n$

$$\begin{aligned} & \underset{\alpha}{\text{maximize}} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \\ & \text{subject to } \sum_{i=1}^n x_i y_i = 0, \quad \alpha_i \geq 0, \quad i=1, 2, 3, 4, \dots, n \end{aligned}$$

\$\xrightarrow{2\pi}\$
내적
\$\xrightarrow{\text{linear}}\$

최적화 문제
\$\Rightarrow\$ 내적으로 표현되어
non-linear 확장이 좋은 성질

KKT (균형 조건) 상태

① Stationarity (미분시 0이 되는 점 존재)

$$\frac{\partial L(w, b, \alpha)}{\partial w} = 0 \Rightarrow w = \sum_i^n \alpha_i x_i y_i \quad \frac{\partial L(w, b, \alpha)}{\partial b} = \sum_i^n \alpha_i y_i = 0$$

② Primal feasibility $y_i (w^T x_i + b) \geq 1$

③ Dual feasibility $\alpha_i \geq 0, i=1, 2, \dots, n$

④ Complementary feasibility (②) x (③)

$$\alpha_i (y_i (w^T x_i + b) - 1) = 0$$

$$\alpha_i (y_i (w^T x_i + b) - 1) = 0$$

① $\alpha_i > 0$ and $y_i (w^T x_i + b) - 1 = 0 \Rightarrow y_i (w^T x_i + b) = 1 \Rightarrow \alpha_i > 0$ plus-plane

② $\alpha_i = 0$ and $y_i (w^T x_i + b) - 1 \neq 0 \quad \alpha_i = 0 \rightarrow \text{Hyper plane } w^T x + b \text{ 를 구축하는데 영향 X}$
 ↳ 이상치에 강건한 이유

$$w^* = \sum_{i \in SV} \alpha_i^* y_i x_i$$

$(\alpha_i^* \geq 0)$

$$\begin{aligned} w^{*T} + b^* &= y_{SV} \\ w^{*T} + b^* &= \sum_i^n \alpha_i^* y_i x_i^T x_{SV} + b^* = y_{SV} \\ &= b^* = y_{SV} - \sum_i^n \alpha_i^* y_i x_i^T x_{SV} \end{aligned}$$

$$\begin{aligned} & \bullet \left[\begin{array}{l} w^{*T} x_{new} + b^* < 0 \Rightarrow \hat{y}_{new} = -1 \\ w^{*T} x_{new} + b^* > 0 \Rightarrow \hat{y}_{new} = 1 \end{array} \right] \quad \hat{y}_{new} = \text{sign}(w^{*T} x_{new} + b^*) \\ & \bullet \quad = \text{sign}(\sum_i^n \alpha_i^* y_i x_i^T x_{new} + b^*) \end{aligned}$$