



SVM(Support Vector Machine)

: Large Margin Classification이라고도 함


: SVM 분류기는 클래스 사이에 가장 폭이 넓은 마진을 찾는 것

: 특성의 스케일에 민감



하드 마진 SVM (Hard Margin SVM)

- 오분류를 허용하지 않는 SVM ↗ 마진오류
↘ 엄격
- 노이즈로 인해 최적의 결정 경계를 잘 못 구하거나, 못 찾을 수 있음



소프트 마진 SVM (Soft Margin SVM)

- 오분류를 허용하는 SVM
- 하드 마진 SVM은 적용하기가 어려우므로 어느 정도의 오류를 허용하는 소프트 마진 SVM을 주로 이용


마진오류 결정 파라미터 : $C \rightarrow \begin{matrix} C \uparrow \\ C \downarrow \end{matrix} \rightarrow \begin{matrix} \text{마진오류} \downarrow \\ \text{마진오류} \uparrow \end{matrix} \Rightarrow \begin{matrix} \text{Hard Margin Classification} \\ \text{Soft Margin Classification} \end{matrix}$

If SVM overfit $\Rightarrow C \downarrow$

Kernel Trick을 이용하여 매핑

kernel = rbf , γ (gamma) $\left\{ \begin{array}{l} \gamma \uparrow \rightarrow \text{종모양(RBF) 좁아짐} \Rightarrow \text{샘플의 영향 범위 작아짐} \\ \gamma \downarrow \rightarrow \text{종모양(RBF) 넓어짐} \Rightarrow \text{결장정제 부드러워짐} \end{array} \right.$
 \Downarrow
규제역할!! \Rightarrow SVM Overfit $\Rightarrow \gamma \downarrow$
 \therefore Underfit $\Rightarrow \gamma \uparrow$

SVM 수식




\vec{w} : 경계면에 직교하는 벡터
 \vec{u} : 임의의 벡터

\vec{u} 가 경계면을 기준으로 어디 (+, -) 에 속하는가?
 $\Rightarrow \vec{w} \cdot \vec{u} \geq C$ (상수) $\Rightarrow +$ 이고 $-$

$$\begin{aligned} & \boxed{\vec{w} \cdot \vec{x}_+ + b \geq 1} \\ & \boxed{\vec{w} \cdot \vec{x}_- + b \leq -1} \end{aligned} \quad (\vec{x}_+ : + \text{샘플}, \vec{x}_- : - \text{샘플})$$

$$\Rightarrow y_i \begin{cases} 1 & \text{for } + \\ -1 & \text{for } - \end{cases} \Rightarrow y_i (\vec{w} \cdot \vec{x}_i + b) - 1 \geq 0$$

↓
 S.V (제약식)



목적: Margin 폭을 최대화

$$\begin{aligned} & \hookrightarrow (\vec{x}_+ - \vec{x}_-) \cdot \frac{\vec{w}}{\|\vec{w}\|} \\ & = \frac{\vec{w} \cdot \vec{x}_+ + b \geq 1}{\vec{w} \cdot \vec{x}_- + b \leq -1} \Rightarrow \vec{w}(\vec{x}_+ - \vec{x}_-) \geq 2 \end{aligned} \quad \Rightarrow \text{WIDTH} = \frac{2}{\|\vec{w}\|}$$

라그랑지 승수 법 이용

$$L(w, b, \alpha) = \frac{1}{2} \|\vec{w}\|^2 - \sum_{i=1}^N \alpha_i |y_i (\vec{w} \cdot \vec{x}_i + b) - 1|$$

\vec{w} 에 대해 편미분 : $\nabla_{\vec{w}} L = \vec{w} - \sum \alpha_i y_i \vec{x}_i = 0$

b 에 대해 편미분 : $\nabla_b L = -\sum \alpha_i y_i = 0$

$$\Rightarrow \vec{w} = \sum_i \alpha_i y_i \vec{x}_i$$

α 에 대한 maximization 문제로 정리

1. α 를 구하면 \vec{w} 구할 수 있음
2. $\alpha \neq 0$, \vec{x} 가 경계선을 정하는 샘플 즉, Support Vector
3. SVM으로 구한 해는 라그랑지 최적화 이론에 의해 최적해 증명 (Local Minima 에 안빠짐)