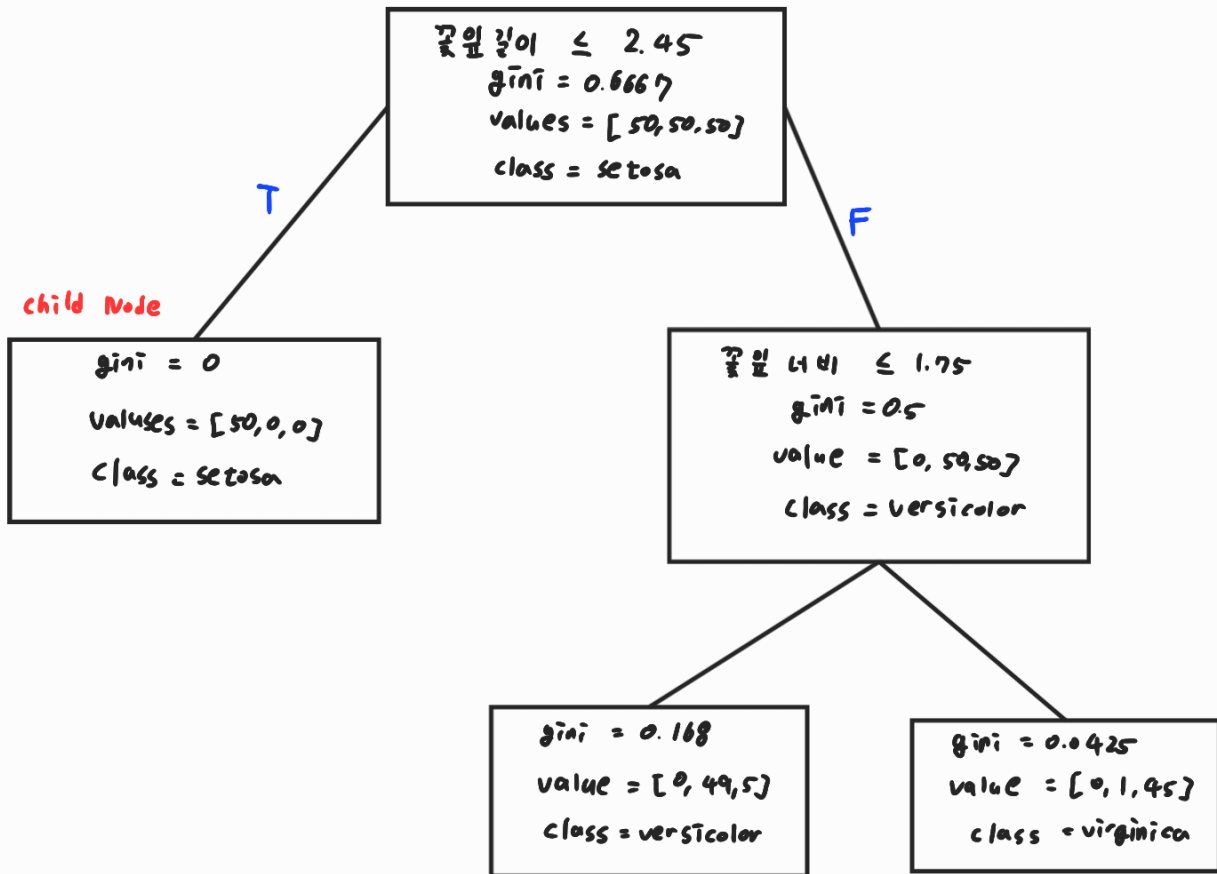


## Root Node



gini 계수 : 불순도(impurity) 측정

$$G_i = 1 - \sum_{k=1}^n p_{i,k}^2 \quad (p_{i,k} = i \text{ 번째 노드에 있는 훈련 샘플 중 } k \text{ 에 속한 비율})$$

max-depth 를 통해  
최대 깊이 조절 가능

※ sklearn 은 이런트리만 만드는 CART 알고리즘 사용

모델 해석 : white box & black box

- white box : 매우 직관적, 결정방식 이해 쉬움
- Black Box : 어떻게 예측 결과가 나오는지 모름

클래스 확률 추정

: k 클래스의 확률 반환  $\Rightarrow$  조건에 만족하는 샘플 / 전체 샘플 (리프노드 안에)

CART 훈련 알고리즘(Classification And Regression Tree)

$$J(k, t_k) = \frac{m_{\text{left}}}{m} G_{\text{left}} + \frac{m_{\text{right}}}{m} G_{\text{right}} \quad (\text{특성: } k, \text{ 특성 } k \text{ 의 임계값: } t_k, \text{ 불순도: } G, m: \text{서브셋 샘플수})$$

→ 최소화해야 하는 CART 비용함수

$\Rightarrow$  서브셋 나누는 것 반복  $\rightarrow$  최대 깊이 = 불순도 줄이는 분할을 반복하여 중지

CART = Greedy Algorithm  $\Rightarrow$  최적의 분할을 가져와 반복  
But, 최적 보장 X, 종종 납득할 만한 솔루션 도출

최적트리 계산 = NP-완전

시간복잡도 =  $O(2^n)$

## 계산 복잡도

: 결정 트리 탐색  $O(\log_2 m) \Rightarrow \therefore$  특성 수와 무관하게 시간복잡도  $O(\log_2 m)$

$\Rightarrow$  But 훈련 알고리즘은 모든 훈련 샘플의 특성 비교

$\Rightarrow O(n \times m \log(m))$

$\rightarrow$  sklearn pre sort = True 옵션 사용하여 정렬 후 훈련  $\Rightarrow$  훈련 시간 감소

## 지니 불순도 또는 엔트로피

- 엔트로피 : 분자가 안정되면 즉, 손실 X 면  $Entropy = 0$

$$H_i = - \sum_{k=1}^K p_{i,k} \log_2(p_{i,k}) \quad (H_i: i\text{-번째 노드 불순도}, k: \text{특성}, p_{i,k} = k\text{-일 확률})$$

## 규제 매개변수

- 비파라미터 모델(nonparametric model) : 훈련되기 전에 **파라미터 수**가 결정되지 않는 모델 ex. 결정 트리
- 파라미터 모델(parametric model) : 미리 정의된 모델 **파라미터 수**를 가지므로 자유도가 제한되고 과대적합될 위험이 줄어들음 ex. 선형 모델

규제 매개변수 : 과대적합을 막기 위해 매개변수 설정(결정 트리의 자유도 및 max\_depth)

### - Decision Tree Classifier의 규제 매개변수

1. **min\_samples\_leaf** : 리프 노드가 가지고 있어야 할 **최소 샘플 수**
2. **min\_weight\_fraction\_leaf** : 가중치가 부여된 전체 샘플 수에서의 **비율**
3. **max\_leaf\_nodes** : 리프 노드의 **최대 수**
4. **max\_features** : 각 노드에서 분할에 사용할 **특성의 최대 수**

※ 참고

**사후 가지치기** = 제한없이 결정 트리를 **가지치기** (제거) 하는 알고리즘

$\Rightarrow$   $\infty$  점수를 통해 p-값이 낮다면 삭제

# DecisionTree Regressor

→ 분류트리와 비슷하지만 **MSE (Mean Squared Error)** 사용

회귀를 위한 **CART 비용 함수**

$$J(k, t_k) = \frac{m_{\text{left}}}{n} \text{MSE}_{\text{left}} + \frac{m_{\text{right}}}{n} \text{MSE}_{\text{right}} \quad \left( \text{MSE}_{\text{node}} = \sum (y - \hat{y})^2, \hat{y}_{\text{node}} = \frac{1}{m_{\text{node}}} \sum y^{(i)} \right)$$

## 불안정성

- 결정 트리는 계단 모양의 결정 경계 생성
- 이상치에 매우 민감
- 일반화를 위해 **PCA 기법**을 통해 훈련 데이터를 더 좋은 방향으로 회전
- 확률적이기 때문에 같은 훈련 데이터에서도 다른 모델 얻을 수 있음